

# Behavioral Context Recognition

Praktikum Mustererkennung

# Aufbau


1. Multi-stream Temporal Convolutional Networks
2. Adversarial Autoencoder (AAE)
3. Rekurrierende Neuronale Netze

## 1. Multi-stream Temporal Convolutional Networks

## 2. Adversarial Autoencoder (AAE)

## 3. Rekurrierende Neuronale Netze

## Saeed et al.: [...] multi-stream temporal convolutional networks



## Saeed et al.: [...] multi-stream temporal convolutional networks

- ▶ **Learning behavioral context recognition with multi-stream temporal convolutional networks** [Saeed et al. 18]
- ▶ Aufteilung der Daten bezüglich ihrer Art (Audio, Acc-Sensor Daten)
- ▶ Netze für die Modalitäten werden in einem weiteren Netz zusammengeführt
- ▶ *modal-specific networks* nutzen *depthwise separable convolution*
- ▶ Zusammenführung der Netze sowohl mit Konkatenation als auch Convolution
- ▶ Keine Verbesserung gegenüber standardmäßiger Convolution, aber weniger Parameter und damit effizienter

1. Multi-stream Temporal Convolutional Networks

2. Adversarial Autoencoder (AAE)

3. Rekurrierende Neuronale Netze

# Probleme bei den Sensordaten

- ▶ fehlende Sensordaten
  - ▶ keine WLAN-Verbindung
  - ▶ Entscheidung, keine Smartwatch zu tragen
  - ▶ Verbot, Bewegungsdaten auszuwerten
- ▶ unbalancierte Datenlage
  - ▶ „at the beach“ seltenere Aktivität als „standing“

## Lösungsansatz:

- ▶ Adversarial Autoencoder [SAO18]
  - ▶ Rekonstruktion fehlender Sensordaten
  - ▶ Generierung von realistischen synthetischen Daten

# Adversarial Autoencoder




Abbildung: Framework für Kontextklassifizierung mit fehlenden Sensordaten [SAO18]



## Evaluierung

- ▶ Klassifizierungsergebnisse vergleichbar mit leichteren Standardtechniken (Mean, Fill-1, PCA)  $\Rightarrow$  liegt vermutlich an zu geringem Umfang der fehlenden Daten
- ▶ eingebautes GAN kann komplette realistische Datensätze synthetisieren
  - ▶ Training nur auf synthetischen Daten liefert fast so gute Ergebnisse wie Training auf echten Daten (0.715 zu 0.752)
  - ▶ Ergänzung von Daten für seltene Label könnte Klassifikation robuster machen
- ▶ Möglichkeit sich mit interessanten Techniken (GAN, Autoencoder) auseinanderzusetzen


1. Multi-stream Temporal Convolutional Networks

2. Adversarial Autoencoder (AAE)

3. Rekurrierende Neuronale Netze

# Inoue, M., Inoue, S. & Nishida : Deep recurrent neural network for mobile human activity recognition with high throughput

- ▶ Nutzung von Rekurreierenden Neuronalen Netzen (RNN)
- ▶ Datensatz: von HASC (hasc.jp) mit Aktivitäten wie "stay", "walk", "jog", "skip", "stair up", "stair down"



<sup>1</sup>image source:

[https://de.wikipedia.org/wiki/Rekurrentes\\_neuronales\\_Netz#/media/File:Neuronal\\_Networks\\_Feedback.png](https://de.wikipedia.org/wiki/Rekurrentes_neuronales_Netz#/media/File:Neuronal_Networks_Feedback.png)

# Inoue, M., Inoue, S. & Nishida : Deep recurrent neural network for mobile human activity recognition with high throughput

## Vorzüge

- ▶ keine Features von vornherein benötigt
- ▶ wenige Knoten im neuronalen Netz
- ▶ gute Performance
  - ▶ vorausgesetzt, die Feature-Zeit wird mit einberechnet
  - ▶ vorausgesetzt, die Datasets sind vergleichbar




Fig. 4 Accuracy of comparative methods and best model

Table 5 Evaluation of throughput

	Feature (ms)	Recognition (ms)	Total (ms)
Decision tree	11.027	0.004	11.031
SVM	11.027	0.123	11.150
Random forest	11.027	0.056	11.083
DRNN	–	1.347	1.347

# Quellen I

- [SAO18] Aaqib Saeed, Tanir Ozcelebi und Johan Lukkien. „Synthesizing and Reconstructing Missing Sensory Modalities in Behavioral Context Recognition“. In: *Sensors18*. NCBI, 2018.
- [Saeed et al. 18] Aaqib Saeed u. a. „Learning behavioral context recognition with multi-stream temporal convolutional networks“. In: *arXiv preprint arXiv:1808.08766* (2018).