

# **Behavioral Context Recognition**

Praktikum Mustererkennung II



- 1. Was wir bisher gemacht haben
- 2. Probleme und offene Fragen
- 3. Pläne für die Zukunft

- 1. Was wir bisher gemacht haben
- 2. Probleme und offene Fragen
- 3. Pläne für die Zukunft



## Kennenlernen des Datensatzes und Benutzererkennung



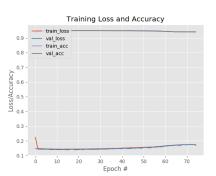
### Klassifizierung mit Tensorflow

- Erstellung eines ersten Netzes
- Training auf dem gesamten Datensatz
- Erste Versuche der Multi-Label-Klassifizierung

Layer (type)	Output Shape	Param #
dense_1 (Dense)	(None, 64)	14464
activation_1 (Activation)	(None, 64)	θ
dense_2 (Dense)	(None, 32)	2080
activation_2 (Activation)	(None, 32)	0
dropout_1 (Dropout)	(None, 32)	θ
dense_3 (Dense)	(None, 64)	2112
activation_3 (Activation)	(None, 64)	θ
dropout_2 (Dropout)	(None, 64)	0
dense_4 (Dense)	(None, 512)	33280
activation_4 (Activation)	(None, 512)	θ
dropout_3 (Dropout)	(None, 512)	θ
dense_5 (Dense)	(None, 51)	26163
activation_5 (Activation)	(None, 51)	0



### Klassifizierung mit Tensorflow - Erste Ergebnisse





### Klassifizierung mit Tensorflow - Erste Ergebnisse



- Manuelle Verifikation deutet wesentlich schlechtere Resultate an
- Erste Klassifizierung möglich

### Probleme:

Gewichtung der NaN-Labels



- ► Finden einer geeigneten Verlustfunktion
- Multi-Label-Evaluation
- Verwenden von Gewichten

### Klassifizierung mit XGBoost

▶ Bibliothek für GPU-unterstützte und verteilte Berechnung von *Gradient Boosted Trees* 

#### Vorteile:

- ▶ liefert gute Ergebnisse für tabulare Daten
- Scikit-learn API vorhanden → Verwendung der Scikit-learn Infrastruktur gut möglich, insbesondere OneVsRestClassifier
- ▶ gute Interpretierbarkeit →



Hyperparametertuning mit randomisierter Suche und Bayesian Optimization



- 1. Was wir bisher gemacht haben
- 2. Probleme und offene Fragen
- 3. Pläne für die Zukunft



### Learning Rate und N\_Estimators

### NaN-Werte in den Labeln





- 1. Was wir bisher gemacht haben
- 2. Probleme und offene Fragen
- 3. Pläne für die Zukunft